Revisión de Machine Learning

Primera sesión: aprendizaje estadístico, recomendación y redes MLP

Iván Carrera

Escuela Politécnica Nacional
Recuperación de Información

Objetivos de la revisión

- Distinguir predicción, agrupamiento, recomendación y asociación.
- Explicar qué aprende cada familia de modelos y sus supuestos.
- Elegir una representación, un modelo y una evaluación adecuados.
- Relacionar los modelos clásicos con softmax y redes MLP.
- Comparar métodos con evidencia y analizar sus errores.

Mapa de contenidos

Fundamentos y aprendizaje supervisado

1. Fundamentos y evaluación.
2. Naive Bayes.
3. Regresión lineal y logística.
4. Vecinos y centroides.
5. SVM.
6. Árboles y ensambles.

Estructura, personalización y redes

7. Clustering.
8. PCA y SVD truncada.
9. Sistemas de recomendación.
10. Reglas de asociación.
11. Softmax.
12. MLP para regresión y clasificación.

Problemas de aprendizaje

Tarea	Información disponible	Resultado esperado
Regresión	Ejemplos con valor objetivo	Valor numérico
Clasificación	Ejemplos etiquetados	Clase o probabilidad
Clustering	Ejemplos sin etiquetas	Grupos de similitud
Recomendación	Contenido e interacciones	Ítems ordenados
Asociación	Conjuntos de ítems	Patrones y reglas

Una misma colección puede admitir varias tareas. La pregunta define el problema, no el nombre del algoritmo.

Ejemplos: estimar precios, detectar fallas, segmentar clientes y sugerir películas.

Referencia: Aggarwal, Data Mining: The Textbook, cap. 1.

Datos, representación y modelo

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}, \qquad X \in \mathbb{R}^{n \times d}, \qquad \hat{y}_i = f_\theta(\mathbf{x}_i).$$

- n: número de instancias. d: número de características.
- $\mathbf{x}_i$: representación de la instancia. y_i: objetivo observado.
- θ: parámetros aprendidos, como pesos, centroides o divisiones.
- Hiperparámetros: decisiones externas, como k, profundidad o regularización.

Ejemplo: una fruta se representa por peso, diámetro y acidez. Su etiqueta puede ser manzana, naranja o pera.

Referencia: Aggarwal, Data Mining: The Textbook, caps. 1–2.

Pérdida y generalización

$$\hat{\theta} = \arg\min_{\theta} \left[\frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f_\theta(\mathbf{x}_i)) + \lambda \Omega(\theta) \right].$$

- ℓ: penaliza el error de predicción sobre un ejemplo.
- Ω: penaliza la complejidad. λ: intensidad de regularización.
- Entrenar reduce la pérdida observada. Generalizar exige funcionar en datos nuevos.
- Subajuste: modelo demasiado limitado. Sobreajuste: aprende particularidades del entrenamiento.

La complejidad útil depende de los datos, el ruido y el tamaño de la muestra.

Referencia: Aggarwal, Data Mining: The Textbook, secs. 10.9 y 11.8.

Subajuste y sobreajuste

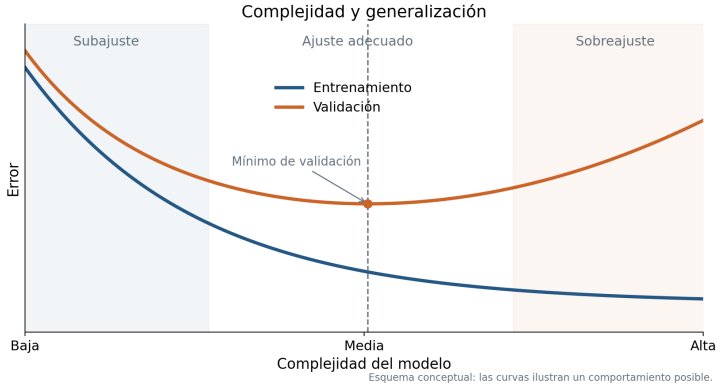


Figura 1: El mínimo de validación orienta la elección de complejidad.

El error de prueba debe estimarse después de elegir el modelo.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 11.8.

Separación de datos y fuga de información

- Entrenamiento: ajustar parámetros y transformaciones.
- Validación o validación cruzada: elegir hiperparámetros.
- Prueba: estimar el desempeño final sin seguir ajustando.
- Ajustar escalamiento, selección de características e imputación dentro de cada partición de entrenamiento.
- Separar por usuario, grupo o tiempo cuando las dependencias del problema lo exijan.

Ejemplo de fuga

Calcular la media y la desviación estándar con todos los datos antes de separarlos permite que la prueba influya en el escalamiento.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.9.1.

Evaluación de clasificación

	Predicho positivo	Predicho negativo
Real positivo	TP	FN
Real negativo	FP	TN

$$P = \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + FN}, \qquad F_1 = \frac{2PR}{P + R}.$$

- Accuracy: proporción total de aciertos. Puede ocultar el desbalance.
- Macro: promedio por clase, todas pesan igual.
- Micro: agrega los conteos antes de calcular la métrica.

Ejemplo: $TP = 8$, $FP = 2$, $FN = 4$ da $P = 0.80$, $R = 0.67$, $F_1 = 0.73$.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.9.2.

Evaluación de regresión

$$\mathrm{MAE} = \frac{1}{n}\sum_i |y_i - \hat{y}_i|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}.$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

MAE y RMSE conservan las unidades del objetivo. RMSE penaliza más los errores grandes.

R^2 compara con predecir la media del conjunto evaluado y puede ser negativo.

Baseline

Comparar con una predicción constante. La media minimiza el error cuadrático sobre entrenamiento y la mediana minimiza el error absoluto.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 11.5.

Naive Bayes: clasificación probabilística

$$P(c \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid c)P(c)}{P(\mathbf{x})}, \qquad \hat{c} = \arg\max_c P(c) \prod_{j=1}^{d} P(x_j \mid c).$$

- $P(c)$: probabilidad previa de la clase.
- $P(\mathbf{x} \mid c)$: verosimilitud de las características dada la clase.
- Supuesto: independencia condicional de las características dada la clase.

Sensores correlacionados pueden violar el supuesto, pero el clasificador puede seguir siendo un baseline competitivo. Sus probabilidades pueden requerir calibración.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.5.1.

Variantes y suavizado

Variante	Tipo de característica	Ejemplo
Gaussian	Valor continuo	Temperatura de un sensor
Bernoulli	Presencia/ausencia	Indicador de vibración alta
Multinomial	Conteos por categoría	Conteos de eventos de una máquina

Para una característica categórica x_j con m_j valores posibles:

$$P(x_j = v \mid c) = \frac{n_{jvc} + \alpha}{n_c + \alpha m_j}.$$

n_{jvc}: ejemplos de clase c con valor v. n_c: ejemplos de esa clase. $\alpha > 0$: suavizado, Laplace cuando $\alpha = 1$.

Una categoría no observada en entrenamiento conserva probabilidad positiva.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.5.1.

Ejemplo: diagnóstico de una máquina

Dos estados tienen igual probabilidad previa. Cada estado tiene 10 ejemplos. Observamos un indicador binario de vibración alta.

Estado	$P(c)$	Vibración alta	Total
Falla	0.5	8	10
Normal	0.5	1	10

Con suavizado de Laplace y dos valores posibles:

$$P(\text{alta} \mid F) = \frac{9}{12}, \qquad P(\text{alta} \mid N) = \frac{2}{12}.$$

Scores: $0.5(9/12) = 0.375$ y $0.5(2/12) = 0.0833$.

Posterior normalizado: $P(F \mid \text{alta}) = 9/11 \approx 0.818$. Con varias características usamos logaritmos para sumar la evidencia.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.5.1. Ejemplo didáctico propio.

Regresión lineal

$$\hat{y} = \mathbf{w}^\top \mathbf{x} + b, \qquad \min_{\mathbf{w},b} \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2.$$

Los pesos describen cómo cambia la predicción al variar una característica, manteniendo las demás constantes.

Ejemplo: predecir el precio de una vivienda usando superficie y antigüedad.

- La relación es lineal en los parámetros.
- Los valores atípicos pueden dominar el error cuadrático.
- Un coeficiente describe una relación predictiva, sin establecer causalidad.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 11.5.1.

Regularización Ridge y Lasso

$$\text{Ridge}: \quad \text{MSE} + \lambda \|\mathbf{w}\|_2^2, \qquad \text{Lasso}: \quad \text{MSE} + \lambda \|\mathbf{w}\|_1.$$

- Ridge reduce magnitudes y estabiliza pesos ante características correlacionadas.
- Lasso puede llevar algunos pesos exactamente a cero.
- A mayor λ, mayor penalización y posible subajuste.
- El escalamiento modifica la penalización efectiva de cada característica.

Elegimos λ con validación. Usualmente dejamos el intercepto sin penalizar.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 11.5. Complemento docente sobre regularización.

Regresión logística binaria

$$z = \mathbf{w}^\top \mathbf{x} + b, \qquad p = P(y = 1 \mid \mathbf{x}) = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

$$\ell(y, p) = -y \log p - (1 - y) \log(1 - p).$$

- z: score real o logit. p: probabilidad modelada de la clase positiva.
- El entrenamiento minimiza la entropía cruzada binaria.
- La regla $p \geq \tau$ convierte la probabilidad en una decisión.

El modelo estima probabilidades directamente. Naive Bayes modela la verosimilitud por clase y aplica Bayes.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.5.2.

Probabilidad, umbral y costo del error

Con $p = 0.40$, el mismo modelo decide:

Umbral	Decisión	Efecto típico al bajar el umbral
$\tau = 0.50$	Negativo	
$\tau = 0.30$	Positivo	Mayor recall, más falsos positivos

Para detectar fallas, detener una máquina sana y dejar pasar una falla pueden tener costos distintos.

El umbral se elige con validación según esos costos o una métrica objetivo.

Interpretación

Una probabilidad alta del modelo no garantiza certeza ni calibración adecuada.

Referencia: Aggarwal, Data Mining: The Textbook, secs. 10.5.2 y 10.9.

Distancias y similitudes

$$d_E(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_j (x_j - z_j)^2}, \qquad \cos(\mathbf{x}, \mathbf{z}) = \frac{\mathbf{x}^\top \mathbf{z}}{\|\mathbf{x}\| \|\mathbf{z}\|}.$$

- Euclidiana: cercanía geométrica. Sensible a las escalas.
- Coseno: alineación entre vectores no nulos. Compara patrones de características.
- Jaccard: $|A \cap B| / |A \cup B|$ para conjuntos con unión no vacía.

Para vectores unitarios, $\|\mathbf{x} - \mathbf{z}\|^2 = 2(1 - \cos(\mathbf{x}, \mathbf{z}))$.

La representación determina qué significa "parecido".

Referencia: Aggarwal, Data Mining: The Textbook, cap. 3.

k vecinos más cercanos

$$\hat{c} = \arg\max_{c} \sum_{i \in N_k(\mathbf{x})} \mathbb{1}[y_i = c].$$

$N_k(\mathbf{x})$: los k ejemplos de entrenamiento más cercanos.

- Clasificación: votación, opcionalmente ponderada por distancia.
- Regresión: promedio de los objetivos de los vecinos.
- k pequeño: sensibilidad a ruido. k grande: suaviza fronteras.
- La predicción exige buscar vecinos y depende de la métrica.

En alta dimensión, ruido y concentración de distancias pueden deteriorar la vecindad.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.8.

Clasificación por centroides

$$\boldsymbol{\mu}_c = \frac{1}{n_c} \sum_{i:y_i=c} \mathbf{x}_i, \qquad \hat{c} = \arg\min_c \|\mathbf{x} - \boldsymbol{\mu}_c\|.$$

Cada clase se resume mediante el promedio de sus ejemplos.

kNN conserva ejemplos locales. **Centroides** conserva un prototipo por clase.

Ejemplo: clasificar una fruta usando peso y diámetro, previamente escalados.
Comparamos la fruta con los centroides de manzanas, naranjas y peras.

Limitación

Una clase con varios subgrupos puede quedar mal representada por un único centroide.

Referencia: Aggarwal, Data Mining: The Textbook, secs. 3 y 10.8. Complemento docente: clasificación por centroides.

SVM: margen y vectores de soporte

Para $y_i \in \{-1, +1\}$, una SVM de margen suave resuelve:

$$\min_{\mathbf{w}, b, \boldsymbol{\xi}} \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_i \xi_i$$

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \qquad \xi_i \geq 0.$$

- $\mathbf{w}^\top \mathbf{x} + b = 0$: frontera de decisión.
- ξ_i: violaciones del margen. C: costo de esas violaciones.
- Los vectores de soporte determinan la solución.

Una SVM lineal produce scores, que no son probabilidades por sí mismos.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.6.

Geometría de SVM y kernels

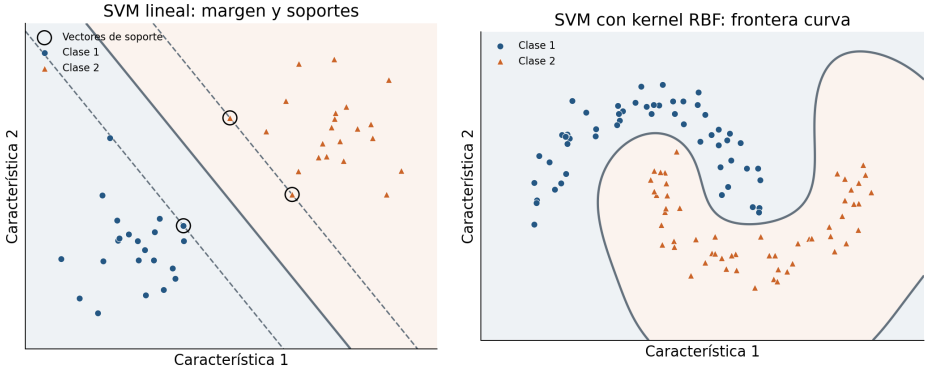


Figura 2: El margen organiza la frontera. Los kernels permiten separaciones no lineales.

Un kernel calcula similitud en un espacio implícito: $K(\mathbf{x}, \mathbf{z}) = \langle \phi(\mathbf{x}), \phi(\mathbf{z}) \rangle$.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.6.

Comparación de clasificadores

Método	Qué aprende o conserva	Aspecto a revisar
Naive Bayes	Distribuciones por clase	Independencia condicional
Logística	Pesos para probabilidades	Regularización y calibración
kNN	Ejemplos de entrenamiento	Métrica y costo de comparación
Centroides	Prototipos de clases	Clases con varios subgrupos
SVM lineal	Separación con margen	Regularización y scores

Comparación válida: mismo conjunto de datos, mismas particiones y mismo protocolo. Cada método puede ajustar sus transformaciones dentro de ese protocolo.

Referencia: Aggarwal, Data Mining: The Textbook, cap. 10.

Árboles de decisión

Un árbol divide el espacio mediante condiciones sobre las características. Cada hoja asigna una clase, una distribución o un valor.

$$G(S) = 1 - \sum_c p_c^2, \qquad H(S) = -\sum_c p_c \log_2 p_c.$$

p_c: proporción de la clase c en el nodo S.

- La división busca reducir la impureza ponderada de los hijos.
- En regresión puede reducir el error cuadrático.
- Profundidad, tamaño mínimo de hoja y poda controlan complejidad.

Ejemplo: un nodo con clases equiprobables tiene Gini 0.5 y entropía 1 bit.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.3.

Divisiones y sobreajuste en árboles

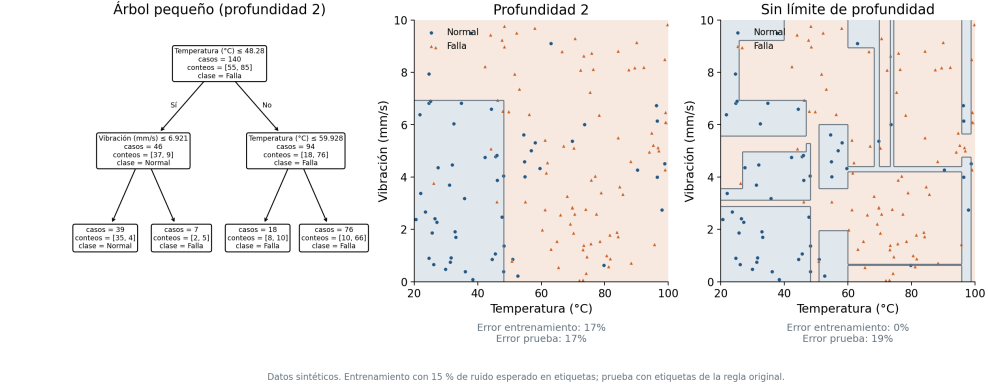


Figura 3: Cada división añade detalle a la frontera de decisión.

Un árbol profundo puede memorizar ejemplos aislados. La interpretación depende del tamaño del árbol.

Bagging y Random Forest

$$\hat{f}(\mathbf{x}) = \frac{1}{B}\sum_{b=1}^{B} f_b(\mathbf{x}) \quad \text{para regresión.}$$

- Bagging entrena modelos sobre muestras bootstrap y combina predicciones.
- En clasificación se combinan votos o probabilidades.
- Random Forest añade selección aleatoria de características en las divisiones.
- Promediar modelos poco correlacionados puede reducir varianza.

B: número de modelos. Más árboles estabilizan el promedio, pero no eliminan la necesidad de controlar sus hiperparámetros.

Referencia: Aggarwal, Data Mining: The Textbook, secs. 11.8.3.1–11.8.3.2.

Boosting y Gradient Boosting

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta h_m(\mathbf{x}).$$

h_m: nuevo modelo. η: tasa de aprendizaje.

- Los modelos se entrenan secuencialmente.
- AdaBoost aumenta el peso de ejemplos difíciles.
- Gradient Boosting ajusta modelos al gradiente negativo de la pérdida.
- Para pérdida cuadrática, ese objetivo corresponde a los residuos.

Número de iteraciones, profundidad y tasa de aprendizaje controlan el ajuste. La validación puede indicar cuándo detener el entrenamiento.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 11.8.3.3. Complemento docente: Gradient Boosting.

Clustering: estructura sin etiquetas

- Agrupar instancias según una representación y una noción de similitud.
- Los grupos descubiertos pueden diferir de las categorías conocidas.
- El algoritmo impone supuestos sobre forma, densidad o conectividad.
- Ejemplos: segmentar clientes o identificar grupos de comportamiento de sensores.

Pregunta de interpretación

¿Los clientes se agrupan por hábitos de compra o solamente por gasto total? La geometría del grupo no explica por sí sola su significado.

Referencia: Aggarwal, Data Mining: The Textbook, caps. 6–7.

k-means

$$\min_{\{C_r, \boldsymbol{\mu}_r\}_{r=1}^{k}} \sum_{r=1}^{k} \sum_{\mathbf{x}_i \in C_r} \|\mathbf{x}_i - \boldsymbol{\mu}_r\|^2.$$

1. Inicializar k centroides.
2. Asignar cada punto al centroide más cercano.
3. Recalcular los centroides y repetir hasta converger.

Optimiza compactación euclidiana y converge a una solución local.

Favorece grupos compactos. Es sensible a inicialización, escala y valores atípicos. En datos con variables de escalas distintas, revisar el efecto de estandarizar.

Referencia: Aggarwal, Data Mining: The Textbook, cap. 6.

Clustering jerárquico

- Aglomerativo: comienza con puntos individuales y fusiona grupos.
- Single linkage: mínima distancia entre miembros de dos grupos.
- Complete linkage: máxima distancia entre miembros.
- Average linkage: promedio de distancias entre miembros.
- Ward: incremento del error cuadrático al fusionar, con geometría euclidiana.

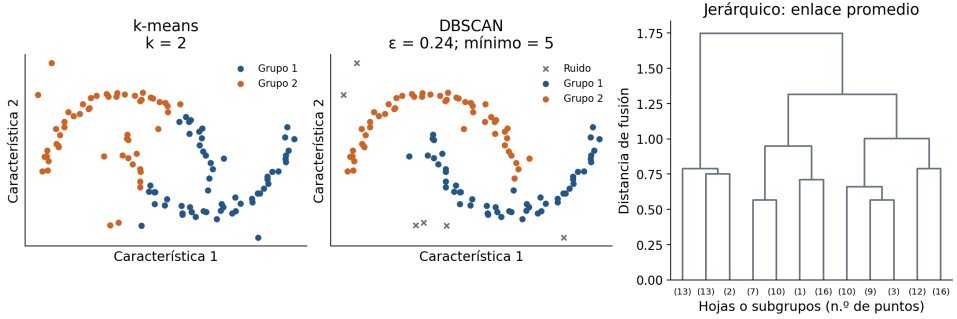
Un dendrograma registra las fusiones. Cortarlo a cierta altura determina grupos.

Distintos criterios de enlace pueden producir estructuras diferentes.

Referencia: Aggarwal, Data Mining: The Textbook, cap. 6.

DBSCAN y formas de los grupos

DBSCAN usa radio ε y mínimo de puntos para distinguir puntos núcleo, frontera y ruido.



Mismos 112 puntos en los tres métodos. Dendrograma abreviado a 12 hojas/subgrupos. Los números de grupo son arbitrarios.

Figura 4: Las familias de clustering utilizan nociones distintas de grupo.

DBSCAN no requiere fijar k, pero depende de escala y densidad.

Referencia: Aggarwal, Data Mining: The Textbook, caps. 6–7.

Evaluación e interpretación de clusters

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}.$$

$a(i)$: distancia media al propio grupo. $b(i)$: menor distancia media a otro grupo.

- Silhouette alta: cohesión y separación según la métrica elegida.
- Con etiquetas externas: comparar con ARI o NMI, sin convertirlas en entrenamiento.
- Inspeccionar características, ejemplos representativos y estabilidad.
- Silhouette puede favorecer ciertas geometrías y requiere al menos dos grupos.

Una buena separación geométrica puede ser poco útil para el usuario.

Referencia: Aggarwal, Data Mining: The Textbook, cap. 6.

Selección de características y PCA

Selección: conservar algunas variables originales. **Transformación:** construir variables nuevas.

$$Z = X_c W_q, \qquad W_q \in \mathbb{R}^{d \times q}, \quad q < d.$$

X_c: datos centrados. Las columnas de W_q son direcciones ortogonales que maximizan sucesivamente la varianza proyectada.

- PCA es no supervisado y depende de las escalas.
- La varianza explicada indica cuánta variabilidad conserva la proyección.
- Una dirección de alta varianza no necesariamente ayuda a predecir la etiqueta.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 2.4.3.1.

SVD truncada y aproximación de matrices

$$X \approx U_q \Sigma_q V_q^\top, \qquad Z = XV_q = U_q \Sigma_q.$$

$X \in \mathbb{R}^{n \times d}$: matriz de datos. $Z \in \mathbb{R}^{n \times q}$: representación reducida.

- U_q y V_q conservan q direcciones singulares.
- Σ_q contiene los valores singulares más grandes.
- La aproximación de rango q conserva los patrones dominantes de la matriz.
- Algunas componentes pueden tener valores negativos.

Ejemplo: resumir muchas mediciones de sensores correlacionados. PCA usa el centrado para describir variación respecto a la media. SVD también puede aplicarse a matrices sin centrar.

Referencia: Aggarwal, Data Mining: The Textbook, secs. 2.4.3.1–2.4.3.2.

Proyección y pérdida de información

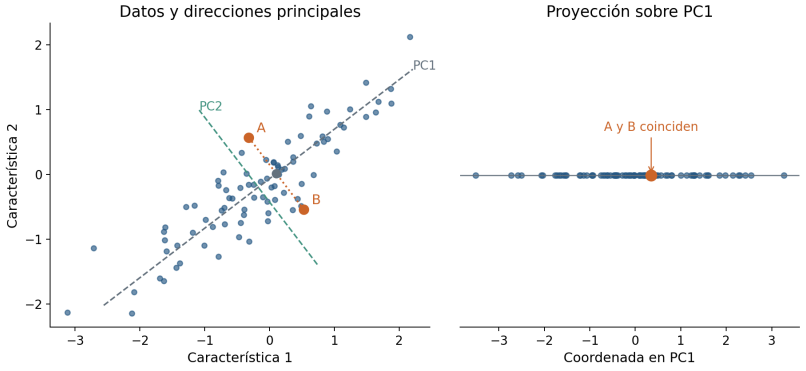


Figura 5: Reducir dimensiones conserva algunas relaciones y pierde otras.

Una visualización en dos dimensiones es una vista parcial del espacio original.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 2.4.3.

Recomendación y matriz usuario–ítem

$$R \in \mathbb{R}^{|U|\times|I|}, \qquad R_{ui} = \text{interacción observada de } u \text{ con } i.$$

- Feedback explícito: rating o valoración.
- Feedback implícito: clic, consumo, compra o tiempo de interacción.
- Ausencia de interacción puede indicar falta de exposición.
- La salida puede ser una valoración estimada o una lista de sugerencias.

Ejemplo: estimar cuánto gustará una película usando preferencias previas. La recomendación combina información del usuario, del ítem y del contexto.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 18.5.

Recomendación por contenido

$$\mathbf{p}_u = \frac{\sum_{i \in H_u} a_{ui} \mathbf{x}_i}{\sum_{i \in H_u} a_{ui}}, \qquad s(u, j) = \cos(\mathbf{p}_u, \mathbf{x}_j).$$

H_u: historial del usuario. a_{ui}: peso positivo de interacción. $\mathbf{x}_i$: representación del contenido. $\mathbf{p}_u$: perfil.

- Recomienda ítems similares a los intereses observados.
- Puede evaluar ítems nuevos si dispone de su contenido.
- Requiere información inicial del usuario y puede limitar diversidad.

Ejemplo: representar películas por género, duración y año de estreno.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 18.5.1.

Filtrado colaborativo por vecinos

Usuario–usuario

- Buscar usuarios con preferencias similares.
- Usar sus interacciones para recomendar.
- Revisar cantidad de ítems compartidos.

Ítem–ítem

- Buscar ítems consumidos por usuarios similares.
- Compararlos con el historial del usuario.
- La similitud proviene de interacciones.

Ejemplo: dos películas pueden ser vecinas por compartir audiencia aunque sus géneros difieran.

Ratings pueden usar correlación centrada. Interacciones binarias pueden usar coseno o Jaccard.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 18.5.2.

Factorización matricial

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^\top \mathbf{q}_i.$$

$$\min \sum_{(u,i)\in\Omega} (r_{ui} - \hat{r}_{ui})^2 + \lambda \left(\sum_u \|\mathbf{p}_u\|^2 + \sum_i \|\mathbf{q}_i\|^2 + \sum_u b_u^2 + \sum_i b_i^2 \right).$$

Ω: ratings observados. μ: media global. b_u, b_i: sesgos. $\mathbf{p}_u, \mathbf{q}_i$: factores latentes de usuario e ítem.

Los valores ausentes no se rellenan como ratings cero. Para feedback implícito se necesitan objetivos y ponderaciones adecuados.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 18.5.5.

Arranque en frío y evaluación

- Usuario nuevo: pedir preferencias o usar popularidad/contexto.
- Ítem nuevo: aprovechar contenido o metadatos.
- MAE y RMSE evalúan valoraciones. Aceptación y diversidad aportan otras perspectivas.
- Separar interacciones por tiempo cuando el objetivo sea recomendar consumo futuro.
- Excluir del conjunto candidato los ítems ya consumidos si la tarea busca novedades.

Límite del dato

Una interacción ausente en la prueba no demuestra desinterés. La evaluación depende de qué ítems pudo conocer el usuario.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 18.5. Complemento docente: protocolo de evaluación.

Ejemplo: predicción de valoraciones

Evaluamos cuatro valoraciones que el modelo no usó al entrenar:

Película	Valoración real	Predicción	Error absoluto
A	5	4	1
B	3	3	0
C	4	3	1
D	2	4	2

$$\mathrm{MAE} = \frac{1+0+1+2}{4} = 1, \qquad \mathrm{RMSE} = \sqrt{\frac{1+0+1+4}{4}} \approx 1.225.$$

Estas métricas evalúan la estimación de valoraciones. Para evaluar una lista de sugerencias también debemos observar su aceptación, variedad y utilidad para el usuario.

Referencia: Aggarwal, Data Mining: The Textbook, secs. 11.5 y 18.5. Ejemplo didáctico propio.

Transacciones, itemsets y reglas

Una transacción T_i es un conjunto de ítems. Un itemset A es un subconjunto.

Una regla $A \Rightarrow B$ tiene antecedente y consecuente disjuntos.

$$\text{supp}(A) = \frac{|\{T_i : A \subseteq T_i\}|}{N}.$$

- Itemset frecuente: supera un soporte mínimo.
- Regla: resume la coocurrencia condicionada por el antecedente.
- Ejemplos: productos comprados juntos o eventos que coinciden en una máquina.

Las reglas describen asociación observada. No demuestran efectos causales.

Referencia: Aggarwal, Data Mining: The Textbook, caps. 4–5.

Soporte, confianza y lift

$$\text{supp}(A \Rightarrow B) = \text{supp}(A \cup B), \qquad \text{conf}(A \Rightarrow B) = \frac{\text{supp}(A \cup B)}{\text{supp}(A)}.$$

$$\text{lift}(A \Rightarrow B) = \frac{\text{conf}(A \Rightarrow B)}{\text{supp}(B)}.$$

- Soporte: frecuencia de observar antecedente y consecuente juntos.
- Confianza: frecuencia de B entre transacciones que contienen A.
- Lift > 1: coocurrencia mayor que la esperada bajo independencia.
- Confianza alta puede deberse solamente a que B es muy frecuente.

Las divisiones requieren soportes positivos.

Referencia: Aggarwal, Data Mining: The Textbook, caps. 4–5.

Ejemplo de reglas de asociación

Transacción	Ítems
1	Pan, leche
2	Pan, leche
3	Pan, mantequilla
4	Leche, mantequilla
5	Pan, leche, mantequilla

$$\text{supp}(\text{pan}) = 4/5, \quad \text{supp}(\text{leche}) = 4/5, \quad \text{supp}(\text{pan,leche}) = 3/5.$$

Para pan $\Rightarrow$ leche: confianza $= 3/4 = 0.75$ y lift $= 0.75/0.8 = 0.9375$.

La confianza parece alta, pero la leche es todavía más frecuente en el conjunto total.

Referencia: Aggarwal, Data Mining: The Textbook, caps. 4–5. Ejemplo didáctico propio.

Apriori y FP-Growth

Propiedad Apriori: si un itemset es frecuente, todos sus subconjuntos también lo son.

1. Contar ítems frecuentes individuales.
2. Generar candidatos mayores con subconjuntos frecuentes.
3. Podar candidatos imposibles y contar soportes.
4. Generar reglas a partir de los itemsets frecuentes.

FP-Growth comprime transacciones en un FP-tree y explora patrones sin generar candidatos de la misma forma que Apriori.

Soporte mínimo bajo puede producir muchos patrones. Revisar redundancia, tamaño de muestra y utilidad.

Referencia: Aggarwal, Data Mining: The Textbook, cap. 4.

Modelo lineal para varias clases

Para K clases mutuamente excluyentes:

$$\mathbf{z} = W\mathbf{x} + \mathbf{b}, \qquad W \in \mathbb{R}^{K \times d}, \quad \mathbf{z} \in \mathbb{R}^{K}.$$

- Cada componente z_c es un score real o logit de una clase.
- Los logits pueden ser negativos y no suman uno.
- Una codificación one-hot tiene un uno en la clase verdadera.

Regresión softmax: clasificador lineal multiclase con salida softmax. A pesar del nombre, resuelve clasificación.

Esta misma transformación puede usarse después de las capas ocultas de un MLP.

Referencia: Zhang et al., Dive into Deep Learning, sec. 4.1.

La función softmax

$$p_c = \text{softmax}(\mathbf{z})_c = \frac{e^{z_c}}{\sum_{j=1}^{K} e^{z_j}}.$$

- $0 < p_c < 1$ para $K > 1$ y logits finitos. $\sum_c p_c = 1$.
- Un score relativo mayor recibe mayor probabilidad.
- $\arg\max_c p_c = \arg\max_c z_c$.

Estabilidad numérica: restar el máximo no cambia el resultado.

$$p_c = \frac{e^{z_c - m}}{\sum_j e^{z_j - m}}, \qquad m = \max_j z_j.$$

Esto evita exponenciales positivas muy grandes.

Referencia: Zhang et al., Dive into Deep Learning, sec. 4.1.

Ejemplo numérico de softmax

Para las clases manzana, naranja y pera:

$$\mathbf{z} = (2, 1, 0), \qquad e^{\mathbf{z}} \approx (7.389, 2.718, 1).$$

$$\mathbf{p} \approx (0.665, 0.245, 0.090).$$

- La predicción es manzana, pero la salida conserva probabilidades para todas las clases.
- Con logits $(12, 11, 10)$ obtenemos la misma distribución.
- Con logits $(0, 0, 0)$ obtenemos $(1/3, 1/3, 1/3)$.

La probabilidad depende de diferencias entre logits, no de un origen absoluto.

Referencia: Zhang et al., Dive into Deep Learning, sec. 4.1. Ejemplo didáctico propio.

Entropía cruzada multiclase

$$\ell(\mathbf{y}, \mathbf{p}) = -\sum_{c=1}^{K} y_c \log p_c = -\log p_{c^*}.$$

c^*: clase verdadera. Para etiquetas one-hot, solo contribuye esa clase.

Si la clase verdadera es manzana:

$$p_{c^*} = 0.665 \Rightarrow \ell \approx 0.408, \qquad p_{c^*} = 0.090 \Rightarrow \ell \approx 2.408.$$

Una predicción incorrecta con mucha confianza recibe una penalización alta.

Minimizar esta pérdida equivale a maximizar la verosimilitud categórica. Con softmax: $\partial \ell / \partial z_c = p_c - y_c$.

Referencia: Zhang et al., Dive into Deep Learning, sec. 4.1.

Binaria, multiclase y multietiqueta

Problema	Salida habitual	Pérdida habitual
Binaria	Una sigmoid	Entropía cruzada binaria
Multiclase	K logits con softmax	Entropía cruzada categórica
Multietiqueta	K sigmoids	Entropía cruzada binaria por etiqueta

Una imagen puede contener un perro y un automóvil simultáneamente. Sus probabilidades por etiqueta no tienen que sumar uno.

Con dos logits, softmax coincide con sigmoid de su diferencia: $p_1 = \sigma(z_1 - z_2)$.

Referencia: Zhang et al., Dive into Deep Learning, sec. 4.1.

Neurona y perceptrón multicapa

Una neurona combina entradas y aplica una activación:

$$a = \phi(\mathbf{w}^\top \mathbf{x} + b).$$

Un MLP de una capa oculta calcula:

$$\mathbf{h} = \phi(W_1 \mathbf{x} + \mathbf{b}_1), \qquad \mathbf{z} = W_2 \mathbf{h} + \mathbf{b}_2.$$

h: características aprendidas. **z**: salida antes de la transformación final.

Las capas ocultas aprenden representaciones útiles para la tarea. Sin activaciones no lineales, una composición de capas afines sigue siendo afín.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.7.

Arquitectura de un MLP

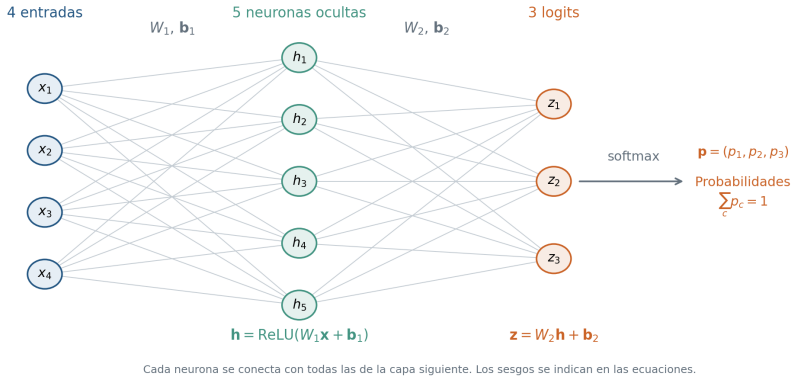


Figura 6: Las capas ocultas transforman la representación antes de predecir.

Para entrada d, capa oculta h y salida K, hay $dh + h + hK + K$ parámetros.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.7.2.

Funciones de activación

$$\mathrm{ReLU}(z) = \max(0, z), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}, \qquad \tanh(z) = \frac{e^{z} - e^{-z}}{e^{z} + e^{-z}}.$$

- ReLU: activación habitual en capas ocultas. Gradiente cero en el lado negativo.
- Sigmoid: acota entre cero y uno, útil para probabilidades binarias.
- Tanh: acota entre -1 y 1.
- Sigmoid y tanh pueden saturarse y producir gradientes pequeños.

La activación de la capa oculta y la transformación de salida cumplen funciones diferentes.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.7. Complemento docente: ReLU.

Salida y pérdida según la tarea

Tarea	Salida	Pérdida típica
Regresión real	Lineal	MSE o MAE
Clasificación binaria	Sigmoid	Entropía cruzada binaria
Clasificación multi-clase	Softmax	Entropía cruzada categórica

El mismo tipo de capas ocultas puede servir para tareas diferentes. El objetivo determina la salida y la pérdida.

Para regresión restringida, revisar si el rango del objetivo requiere otra parametrización.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.7; Zhang et al., Dive into Deep Learning, sec. 4.1.

Propagación hacia adelante: ejemplo

Sea $\mathbf{x} = (1, 2)^\top$, con:

$$W_1 = \begin{pmatrix} 1 & -1 \\ 0.5 & 0.5 \end{pmatrix}, \qquad \mathbf{b}_1 = \mathbf{0}.$$

$$\mathbf{a}_1 = W_1\mathbf{x} = (-1, 1.5)^\top, \qquad \mathbf{h} = \mathrm{ReLU}(\mathbf{a}_1) = (0, 1.5)^\top.$$

Salida de regresión con $W_2 = (2, 1)$ y $b_2 = 0.5$:

$$\hat{y} = W_2\mathbf{h} + b_2 = 2.$$

Si $y = 3$, la pérdida cuadrática de este ejemplo es $(3 - 2)^2 = 1$.

En clasificación, W_2 tendría una fila por logit de salida.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.7.2. Ejemplo didáctico propio.

Backpropagation y actualización de pesos

$$\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}.$$

η: tasa de aprendizaje. Backpropagation aplica la regla de la cadena para calcular los gradientes desde la salida hacia las capas anteriores. Para softmax y entropía cruzada, sobre un ejemplo:

$$\boldsymbol{\delta}_2 = \mathbf{p} - \mathbf{y}, \qquad \frac{\partial \ell}{\partial W_2} = \boldsymbol{\delta}_2 \mathbf{h}^\top.$$

$$\boldsymbol{\delta}_1 = (W_2^\top \boldsymbol{\delta}_2) \odot \phi'(\mathbf{a}_1), \qquad \frac{\partial \ell}{\partial W_1} = \boldsymbol{\delta}_1 \mathbf{x}^\top.$$

$\odot$: producto elemento a elemento. Mini-batches promedian gradientes de varios ejemplos.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.7.2; Zhang et al., Dive into Deep Learning, sec. 4.1.

Entrenamiento y control de complejidad

- Época: recorrido del conjunto de entrenamiento. Batch: ejemplos usados en una actualización.
- Escalamiento e inicialización influyen en el entrenamiento.
- Regularización L2 limita magnitudes de los pesos.
- Parada temprana conserva el modelo con mejor desempeño de validación.
- Dropout desactiva unidades aleatoriamente durante entrenamiento y actúa como regularización.

Comparación necesaria

Un MLP debe justificar su complejidad frente a logística, SVM o ensambles mediante evaluación sobre el mismo problema.

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.7. Complementos docentes: parada temprana y dropout.

Elección del problema y del método

Pregunta	Métodos posibles
¿Cuánto costará una vivienda?	Regresión lineal, árboles, ensambles, MLP
¿Fallará una máquina?	Naive Bayes, logística, SVM, MLP
¿Qué tipos de clientes existen?	k-means, jerárquico, DBSCAN
¿Cómo resumir muchos sensores?	PCA y SVD truncada
¿Qué película sugerir a alguien?	Contenido, colaboración, factores latentes
¿Qué productos se compran juntos?	Itemsets frecuentes y reglas

Primero definimos la tarea, los datos disponibles y el criterio de éxito. Después elegimos el modelo y comprobamos su desempeño.

Referencia: Aggarwal, Data Mining: The Textbook, caps. 1, 2, 4, 6, 10–11 y sec. 18.5.

Estructura de la práctica

Datos	Experimentos	Evidencia
Mediciones etiquetadas	NB, logística, kNN, SVM	F1 macro y errores
Objetivo numérico	Regresión, árboles, ensambles, MLP	MAE/RMSE y curvas
Mediciones sin etiquetas	Clustering, PCA y SVD	Grupos y proyecciones
Usuario–película	Contenido y colaboración	Valoraciones y sugerencias
Cestas de compra	Itemsets y reglas	Soporte, confianza y lift

Softmax y MLP usarán características numéricas y etiquetas conocidas. Cada experimento combina explicación, resultado e interpretación. Los bloques de extensión permiten completar la revisión de forma autónoma.

Protocolo común de comparación

1. Definir pregunta, unidad de análisis y variable objetivo.
2. Separar datos respetando usuarios, grupos o tiempo si corresponde.
3. Ajustar transformaciones dentro del entrenamiento.
4. Entrenar un baseline y elegir hiperparámetros con validación.
5. Evaluar una vez en prueba y analizar errores representativos.

Preguntas para el informe

¿Qué cambió en la representación o el modelo? ¿Qué métrica mejoró? ¿Qué errores permanecen? ¿Qué costo añade el método?

Referencia: Aggarwal, Data Mining: The Textbook, sec. 10.9.

Preguntas de integración

1. Un clasificador obtiene 95% de accuracy y siempre predice la clase mayoritaria. ¿Cómo lo evaluarías?
2. Dos frutas son cercanas por peso y diámetro. ¿Eso garantiza que pertenecen a la misma clase?
3. Una regla tiene confianza 0.9 y lift 1. ¿Qué aporta el antecedente?
4. ¿Qué cambia al añadir una capa oculta no lineal a regresión softmax?
5. Un recomendador reduce RMSE pero siempre sugiere películas muy parecidas. ¿Qué aspecto falta evaluar?

Bibliografía para la primera sesión

- Aggarwal, C. C. (2015). *Data Mining: The Textbook*. Springer.
  - Caps. 2–3: preparación, reducción y similitud.
  - Caps. 4–7: asociación y clustering.
  - Caps. 10–11: clasificación, regresión y ensambles.
  - Sec. 18.5: sistemas de recomendación.
- Zhang, A. y coautores. *Dive into Deep Learning*. Sección 4.1, “Softmax Regression”, en el extracto proporcionado.

Los ejemplos numéricos son didácticos y propios. Las diapositivas señalan los complementos docentes que amplían las secciones principales.